

Urban Style Retail Intelligence System

Informe del Proyecto de Investigación y Desarrollo

AIDA_M (Artificial
Intelligence Driven by
Data)

Escuela Colombiana de
Ingeniería Julio Garavito

Equipo de Desarrollo: Zayra Gutiérrez, Andrés Serrato, Sebastián Cardona

Fecha: Octubre 2025




Made with GAMMA

Task A: Pathfinding & Store Layout Analysis

La simulación del movimiento de clientes mediante algoritmos de búsqueda es esencial para identificar patrones de tráfico y optimizar la disposición física de la tienda (layout).

Análisis con Algoritmo A* (Heurístico)



El uso de A* optimiza la ruta (menor costo) y revela que los clientes prefieren pasar por **Electronics** para llegar a **Clothing**, generando congestión en el pasillo central. El tono rojo intenso indica las áreas de mayor frecuencia de paso.

Análisis con Algoritmo BFS (Exploración Nivelada)




BFS, al explorar nivel por nivel sin heurística, promueve rutas alternativas. Esto resulta en una distribución del tráfico más uniforme, con los clientes utilizando los pasillos de los extremos y reduciendo la congestión en el centro de la tienda.

- La implementación de un **Heatmap Overlay** en Pygame permite visualizar en tiempo real cómo la elección del algoritmo de búsqueda influye directamente en el flujo de clientes y la identificación de puntos críticos de diseño.

Task B: Pronóstico de Demanda con Redes LSTM


Se empleó una red LSTM de tres capas (128 unidades) para predecir las ventas semanales futuras por categoría, basándose en secuencias históricas y datos suavizados.

Beauty Forecast




MAE: 700.76 | RMSE: 821.3. La predicción indica un aumento moderado en las ventas futuras, respaldando la necesidad de optimizar el inventario de productos de belleza.

Clothing Forecast



MAE: 747.5 | RMSE: 906.46. Se observa estabilidad con un leve incremento. El modelo sugiere una planificación de existencias conservadora para esta categoría.

Electronics Forecast




MAE: 1241.2 | RMSE: 1494.6. La mayor variabilidad del error sugiere una tendencia a la baja, alertando sobre la necesidad de implementar promociones inmediatas o ajustar drásticamente el inventario.

La evaluación con **MAE** y **RMSE** cuantifica el error promedio de predicción en unidades monetarias, proporcionando una base sólida para la toma de decisiones de inventario y promoción.

Task C: Maximización de Revenue con Dynamic Pricing (RL)

El agente PPO se entrena en un entorno Gym simulando la elasticidad precio para ajustar dinámicamente los precios y maximizar la recompensa (ingresos acumulados).




El pricing dinámico con RL (PPO) consistentemente supera al pricing estático, adaptándose a las fluctuaciones de demanda simuladas. Se observa una mejora significativa en el revenue total en las tres categorías principales.

Categoría	Mejora de Revenue RL	Observación Clave
Beauty	Hasta 13.7%	Muestra la mayor ganancia porcentual en escenarios de alta variabilidad.
Electronics	9.19%	El agente ajusta los precios para compensar la tendencia a la baja pronosticada.
Clothing	5.68%	Mejora estable, demostrando la capacidad de RL para optimizar ingresos incluso con demanda menos volátil.

Task D: Generación de Contenido Promocional con DCGAN


Se empleó una Deep Convolutional GAN para generar imágenes de prendas de vestir, partiendo del dataset Fashion-MNIST, con el fin de automatizar la creación de material publicitario.

Fase Inicial de Entrenamiento (Ruido)



Al inicio (pocas épocas), el discriminador tiene baja precisión (0.4-0.6) y el generador produce solo ruido aleatorio, sin formas reconocibles. Esto indica que el modelo está en la etapa de aprendizaje básico de los patrones de color y textura.

Fase de Convergencia (Imágenes Reconocibles)



Tras 50 épocas, las pérdidas se estabilizan. El generador crea prendas de vestir (camisetas, pantalones) con formas definidas, adecuadas para ser utilizadas como borradores o bases de pósters promocionales para UrbanStyle.